

Classificação de Câncer de Mama com Machine Learning

Apoio ao diagnóstico (maligno × benigno) a partir de imagens de FNA

Parte	Integrante	Responsabilidade
A	Luis Conrado	Dataset, contexto e Análise Exploratória (EDA)
B	Beatriz Honey	Encoding, correlação, split e pipeline de pré-processamento
C	Pedro Henrique Klein	Modelagem (≥ 2 algoritmos de classificação)
D	Rodrigo Edson Fernandes	Avaliação, métricas e explicabilidade (SHAP)
E	Alexandre Akio	Integração, documentação, relatório e vídeo

Grupo 17 • Repositório: github.com/LuisEduardoOuroConrado/tech-challenge-fase1-g17
Vídeo de apresentação: <https://youtu.be/8IzSGtkSNxo>

Resumo

Este trabalho desenvolve um sistema de **Machine Learning** para apoiar a classificação de tumores de mama em **malignos (M)** ou **benignos (B)**, utilizando o dataset público *Breast Cancer Wisconsin (Diagnostic)*, com 569 amostras e 30 atributos numéricos extraídos de imagens de aspiração por agulha fina (FNA). O pipeline cobre análise exploratória, pré-processamento sem vazamento de dados (*data leakage*), comparação de seis algoritmos por validação cruzada e avaliação final em conjunto de teste independente. O modelo selecionado — **Regressão Logística** — alcançou **96,5% de acurácia** e **92,9% de recall** para a classe maligna no teste. Adota-se o **recall da classe maligna** como métrica principal, por ser o erro de *falso negativo* o de maior gravidade clínica. Reforça-se que a solução é uma ferramenta de **apoio** — a decisão final é sempre do profissional de saúde.

1. Introdução e contexto clínico

O câncer de mama está entre os tipos de câncer mais frequentes em mulheres, e o diagnóstico precoce é determinante para melhorar o prognóstico e reduzir a mortalidade. A análise de imagens de FNA (*Fine Needle Aspiration*) de uma massa mamária permite extrair características numéricas do núcleo celular — tamanho, textura, irregularidade da borda, concavidade, entre outras — que podem ser exploradas por algoritmos de aprendizado de máquina.

O objetivo do projeto é construir um classificador binário que distinga tumores malignos de benignos a partir dessas características. Em um contexto clínico, um **falso negativo** (classificar como benigno um tumor de fato maligno) costuma ser mais grave do que um **falso positivo**, pois adia um tratamento essencial. Por isso, a métrica priorizada é o **recall da classe maligna**.

***Importante:** o sistema apoia a decisão do profissional de saúde — nunca a substitui. O médico tem sempre a palavra final.*

2. Dataset

Característica	Detalhe
Base	Breast Cancer Wisconsin (Diagnostic)
Fonte	Kaggle / UCI Machine Learning Repository
Amostras	569 (357 benignos / 212 malignos)
Atributos	30 numéricos (10 medidas × mean / se / worst)
Alvo	diagnosis → M (maligno) / B (benigno) → 1 / 0
Qualidade	0 nulos e 0 duplicatas (após remover coluna vazia 'Unnamed: 32')

As 10 medidas de base são: *radius*, *texture*, *perimeter*, *area*, *smoothness*, *compactness*, *concavity*, *concave points*, *symmetry* e *fractal dimension*. Cada uma aparece em três agregações: média (*_mean*), erro padrão (*_se*) e pior valor (*_worst*).

3. Análise Exploratória — Parte A

A base é limpa: 569 amostras, sem valores nulos e sem duplicatas. As classes apresentam **desbalanceamento leve**, com predomínio de casos benignos (62,7% B contra 37,3% M), o que justifica o uso de **estratificação** na divisão treino/teste e a atenção a métricas além da acurácia.




Figura 1 — Distribuição das classes no dataset.

Comparando as distribuições das features `_mean` por diagnóstico, observa-se que tumores malignos tendem a apresentar valores maiores de tamanho e irregularidade (raio, área, concavidade e *concave points*), com clara separação entre as curvas.




Figura 2 — Distribuições de features selecionadas por diagnóstico.

A matriz de correlação evidencia forte associação entre medidas de tamanho — *radius*, *perimeter* e *area* — antecipando um problema de **multicolinearidade** a ser tratado no pré-processamento.




Figura 3 — Matriz de correlação das features *_mean.

4. Pré-processamento — Parte B

- **Remoção do id:** identificador sem valor preditivo, descartado.
- **Encoding do alvo:** diagnosis convertido de texto para número — B = 0, M = 1.
- **Análise de correlação:** foram identificados **21 pares** de features com correlação acima de 0,9 (ex.: radius_mean × perimeter_mean ≈ 0,998), confirmando multicolinearidade.
- **Split estratificado 80/20:** 455 amostras de treino e 114 de teste, preservando a proporção de classes (≈ 62,6% B / 37,4% M em ambos os conjuntos).
- **Pipeline com StandardScaler:** a padronização é ajustada **apenas no treino** e aplicada ao teste, evitando vazamento de dados (*data leakage*).

*O uso de **Pipeline** garante que todo o pré-processamento seja reproduzível e que a escala aprendida no treino nunca contamine a avaliação do teste.*

5. Modelagem — Parte C

Foram treinados e comparados **seis algoritmos** de classificação: Regressão Logística, SVM (kernel RBF), Random Forest, KNN, Naive Bayes e Árvore de Decisão. A seleção usou **validação cruzada estratificada (5-fold)** aplicada somente ao conjunto de treino, de modo a **não usar o teste** para escolher o modelo. Cada algoritmo foi encapsulado em um Pipeline com StandardScaler para manter a padronização correta dentro de cada *fold*.

Modelo	Accuracy	Precision (M)	Recall (M)	F1 (M)
Regressão Logística	0,974	0,977	0,953	0,964
SVM (RBF)	0,971	0,977	0,947	0,961
Random Forest	0,963	0,964	0,935	0,949
KNN	0,965	0,988	0,918	0,951
Naive Bayes	0,938	0,925	0,912	0,917
Árvore de Decisão	0,921	0,920	0,865	0,890

Tabela 1 — Média das métricas na validação cruzada (5-fold) sobre o treino. Linha destacada = modelo escolhido.




Figura 4 — Comparação visual dos modelos na validação cruzada.

A **Regressão Logística** apresentou o melhor equilíbrio, liderando em recall e F1 da classe maligna e mantendo alta acurácia. Além do desempenho, é um modelo **interpretável** (seus coeficientes têm leitura direta), o que é desejável em aplicações de saúde. Por isso foi selecionada como modelo final e treinada com todo o conjunto de treino (455 amostras).

6. Avaliação e explicabilidade — Parte D

Avaliação final no conjunto de teste independente (114 amostras nunca vistas):

Métrica (classe Maligna)	Valor
Accuracy	0,965
Precision	0,975
Recall (métrica principal)	0,929
F1-score	0,951




Figura 5 — Matriz de confusão no teste. $TN=71$, $FP=1$, $FN=3$, $TP=39$.

Por que o recall da classe maligna é a métrica principal?

O erro mais crítico é o **falso negativo**: um paciente com tumor maligno classificado como benigno deixa de receber tratamento no tempo adequado, com consequências potencialmente fatais. Um **falso positivo**, por outro lado, leva a exames adicionais (como biópsia) e gera ansiedade, mas não coloca a vida em risco da mesma forma. Maximizar o recall da classe maligna significa minimizar os falsos negativos.

No teste, o modelo produziu apenas **1 falso positivo** e **3 falsos negativos**, identificando corretamente 39 dos 42 casos malignos — recall de 92,9%.

Explicabilidade (coeficientes e SHAP)

A interpretabilidade foi analisada por dois caminhos complementares: os **coeficientes** da Regressão Logística e os valores **SHAP**. Features como *concave points*, *radius*, *perimeter* e *area* aparecem entre as mais influentes para a predição de malignidade, coerentes com a intuição clínica (tumores malignos tendem a ser maiores e mais irregulares). Vale notar que a correlação isolada de uma variável com o alvo não determina, sozinha, sua importância no modelo: os coeficientes refletem a contribuição de cada feature **considerando as demais**, o que é relevante diante da multicolinearidade observada na

EDA.

7. Discussão crítica e limitações

Os resultados são promissores ($\approx 96\%$ de acurácia e $92,9\%$ de recall maligno), mas **não** tornam o modelo apto ao uso clínico direto. As principais limitações são: (i) o tamanho reduzido e a origem específica do dataset, que limitam a generalização para outras populações e equipamentos; (ii) a ausência de validação externa em dados independentes; e (iii) a necessidade de calibração de *threshold* caso se deseje reduzir ainda mais os falsos negativos.

*Na prática, o modelo deve ser tratado como **ferramenta de apoio à decisão**, útil para triagem e priorização de casos que merecem maior atenção. A decisão final permanece com o profissional de saúde, que considera histórico clínico e demais exames.*

8. Reprodutibilidade e entregáveis — Parte E

Estrutura do repositório:

```
tech-challenge-fase1-g17/  
■■ data/raw/ # CSV do Kaggle (não versionado)  
■■ notebooks/01_pipeline_eda_preprocessamento.ipynb  
■■ reports/figuras/ # figuras geradas pela EDA  
■■ src/run_eda.py # gera as figuras da EDA sem Jupyter  
■■ requirements.txt  
■■ README.md
```

Como reproduzir:

```
python -m venv .venv  
.\.venv\Scripts\Activate.ps1 # Windows (Linux/Mac: source .venv/bin/activate)  
pip install -r requirements.txt  
# baixar o CSV do Kaggle e salvar em data/raw/data.csv  
python src/run_eda.py # gera as figuras da EDA
```

Dataset: baixar em [kaggle.com/datasets/uciml/breast-cancer-wisconsin-data](https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data) e salvar como `data/raw/data.csv`. É necessário estar logado no Kaggle para o download.

Entregáveis finais: (1) repositório Git com código e README; (2) este relatório técnico em PDF, com link do repositório; (3) vídeo de apresentação de até 15 minutos (YouTube/Vimeo).

9. Conclusão

O projeto entregou um pipeline completo e reproduzível de classificação de câncer de mama, da análise exploratória à avaliação com explicabilidade. A Regressão Logística mostrou-se o melhor compromisso entre desempenho ($96,5\%$ de acurácia, $92,9\%$ de recall maligno) e interpretabilidade. Priorizando o recall da classe maligna, o sistema reduz o risco do erro mais grave — o falso negativo — e se posiciona como uma ferramenta de **apoio** ao diagnóstico, sempre subordinada à avaliação de um profissional de saúde.

Referências

- UCI Machine Learning Repository — Breast Cancer Wisconsin (Diagnostic) Data Set.

- Kaggle — Breast Cancer Wisconsin (Diagnostic): kaggle.com/datasets/uciml/breast-cancer-wisconsin-data
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.
- Lundberg & Lee (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS.

Anexo A — Por que escolhemos este dataset

Este anexo detalha o raciocínio por trás da escolha do dataset **Breast Cancer Wisconsin (Diagnostic)**, as alternativas que avaliamos, os critérios usados na decisão e as limitações que assumimos conscientemente. Complementa a Seção 2 do relatório, que apresenta a base sem discutir o processo de escolha.

A.1. O que o desafio pedia

O Tech Challenge da Fase 1 pede um projeto de Machine Learning aplicado à **saúde da mulher**, com pipeline completo: análise exploratória, pré-processamento, treinamento de pelo menos dois algoritmos de classificação, avaliação por métricas e interpretação crítica dos resultados. O uso de redes neurais convolucionais sobre imagens (mamografia ou ultrassom) é citado como **item opcional**, não obrigatório.

Isso definiu o perfil do dataset que procurávamos: um problema **supervisionado de classificação**, com dados **tabulares**, de domínio de saúde feminina, treinável em notebook comum e com variáveis que pudessem ser interpretadas clinicamente na etapa de explicabilidade.

A.2. Por que câncer de mama

O câncer de mama é o câncer mais incidente entre mulheres no mundo, excetuando o de pele não melanoma. Segundo a Organização Mundial da Saúde, cerca de 2,3 milhões de mulheres foram diagnosticadas em 2022, com aproximadamente 670 mil óbitos no período. No Brasil, o INCA estima dezenas de milhares de novos casos por ano.

Três razões pesaram na escolha do tema:

- **Relevância clínica real.** O diagnóstico precoce muda o prognóstico e reduz a mortalidade, o que dá sentido prático a um modelo de triagem e priorização de casos.
- **Assimetria de erro clara.** Um falso negativo (tumor maligno classificado como benigno) atrasa o tratamento e é muito mais grave que um falso positivo, que gera exames adicionais e ansiedade. Isso nos permitiu **justificar tecnicamente uma métrica principal** — o recall da classe maligna — em vez de escolher acurácia por inércia.
- **Discussão ética natural.** O tema obriga a explicitar que o modelo é ferramenta de **apoio** à decisão, com a palavra final sempre do profissional de saúde. Esse é um dos pontos avaliados no desafio.

A.3. O dataset escolhido

Item	Detalhe
Nome	Breast Cancer Wisconsin (Diagnostic) — WDBC
Origem	University of Wisconsin (Wolberg, Street e Mangasarian, 1993–1995)
Distribuição	UCI Machine Learning Repository e Kaggle (licença aberta, uso acadêmico permitido)
Amostras	569 (357 benignos / 212 malignos)
Atributos	30 numéricos — 10 medidas do núcleo celular × 3 agregações (_mean, _se, _worst)
Alvo	diagnosis → M (maligno) / B (benigno), codificado como 1 / 0

Item	Detalhe
Como os dados nasceram	Características extraídas por software de imagens digitalizadas de punção aspirativa por agulha fina (FNA)
Qualidade	0 valores nulos e 0 duplicatas após remover a coluna vazia Unnamed: 32

As dez medidas de base são: radius, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry e fractal dimension — todas descrevem tamanho, forma e regularidade do núcleo celular, exatamente o tipo de característica que um patologista observa ao microscópio.

A.4. Critérios de decisão

Critério	Por que importa	Como o dataset atende
Aderência ao tema	Requisito do enunciado	Saúde da mulher, com desfecho diagnóstico bem definido
Tipo de problema	Precisávamos comparar classificadores	Classificação binária supervisionada, alvo limpo e balanceado o suficiente
Formato dos dados	Escopo da fase é ML clássico	Tabular, 30 colunas numéricas, direto no scikit-learn
Custo computacional	Sem GPU no grupo	Treino dos 6 modelos com validação cruzada roda em segundos
Volume	Amostras demais travam; de menos não validam	569 registros permitem 5-fold estratificado estável e um teste de 114 amostras
Qualidade	Tempo é o recurso mais escasso	Sem nulos e sem duplicatas: o esforço vai para o pipeline, não para imputação
Interpretabilidade	O desafio cobra explicação dos resultados	Variáveis nomeadas e com significado clínico, o que torna coeficientes e SHAP legíveis
Riqueza didática	Queríamos um caso com decisões reais a tomar	Multicolinearidade forte (21 pares com $ r > 0,9$) e desbalanceamento leve (62,7% / 37,3%) exigem padronização, estratificação e métricas além da acurácia
Reprodutibilidade	O avaliador precisa rodar	Base pública, estável e amplamente documentada, com download em um comando
Ética e privacidade	Dado de saúde é sensível	Já anonimizado: nenhum identificador pessoal, apenas um id numérico que removemos
Comparabilidade	Saber se o resultado é bom	Benchmark clássico da literatura: acurácias de 95% a 98% são o patamar esperado, o que dá referência para os nossos 96,5%

A.5. Alternativas que avaliamos

Dataset	Tema	Por que não foi escolhido
CBIS-DDSM (mamografia)	Câncer de mama por imagem	Dezenas de GB em DICOM e necessidade de CNN e GPU; o enunciado trata imagem como opcional e o prazo não comportava
Breast Ultrasound Images (BUSI)	Ultrassom mamário	Também exige deep learning; ~780 imagens são poucas para treinar CNN do zero sem transfer learning

Dataset	Tema	Por que não foi escolhido
Pima Indians Diabetes	Diabetes em mulheres	Contém zeros biologicamente impossíveis (glicose, pressão, IMC) que exigiriam imputação pesada; apenas 8 atributos, o que empobrece a explicabilidade
Cervical Cancer Risk Factors (UCI)	Câncer de colo do útero	Muitos valores faltantes e desbalanceamento severo da classe positiva; o projeto viraria um exercício de tratamento de missing e reamostragem
PCOS (Kaggle)	Síndrome dos ovários policísticos	Tema pertinente, mas base pequena, com inconsistências de padronização e procedência menos rastreável
Maternal Health Risk (UCI)	Risco na gestação	Problema multiclasse com apenas 6 atributos; pouco material para análise de importância de variáveis

O critério de desempate foi sempre o mesmo: qual base permite entregar **todas** as etapas exigidas com profundidade, em vez de gastar o tempo do grupo em limpeza de dados ou em infraestrutura de treinamento.

A.6. Como o dataset sustenta cada requisito

Requisito do desafio	O que o dataset viabiliza
Análise exploratória	30 variáveis numéricas para distribuições, boxplots, balanceamento e matriz de correlação
Pré-processamento	Coluna vazia e <code>id</code> para limpar, alvo textual para codificar, escalas heterogêneas para padronizar, volume para split estratificado 80/20 (455 / 114)
Dois ou mais algoritmos	Alvo binário permitiu comparar 6 modelos (Regressão Logística, SVM, Random Forest, KNN, Naive Bayes e Árvore) por validação cruzada
Métricas e matriz de confusão	Classe positiva clinicamente relevante torna accuracy, precision, recall e F1 interpretáveis, com recall maligno como métrica principal
Interpretação dos resultados	Features nomeadas permitem ler coeficientes e SHAP: concave points, radius, perimeter e area entre as mais influentes, coerentes com a intuição clínica
Discussão crítica	As limitações conhecidas da base dão material concreto para discutir por que o modelo não está pronto para uso clínico

A.7. Limitações que assumimos

- **Origem restrita.** Os dados vêm de uma única instituição, coletados no início dos anos 1990. Populações, equipamentos e protocolos mudaram desde então; generalização para outros contextos não está demonstrada.
- **Amostra pequena.** Com 114 amostras no teste, cada acerto ou erro desloca as métricas em quase um ponto percentual. Os intervalos de confiança são largos e os números devem ser lidos como ordem de grandeza.
- **Sem metadados demográficos.** Não há idade, etnia ou histórico familiar, então não é possível auditar viés por subgrupo — uma exigência prática em qualquer aplicação real de IA em saúde.
- **Features já extraídas.** O dataset entrega medidas calculadas por software a partir das imagens; o projeto não cobre segmentação nem extração, que na prática são fontes relevantes de erro.

- **Multicolinearidade alta.** Com 21 pares de variáveis fortemente correlacionadas, coeficientes individuais devem ser lidos com cautela: eles refletem a contribuição de cada variável dado o restante do conjunto.
- **Sem validação externa.** Não avaliamos o modelo em uma base independente, o que seria obrigatório antes de qualquer cogitação de uso clínico.

A.8. Ética e privacidade

A base é pública e anonimizada: não há nome, data de nascimento ou qualquer identificador direto, apenas um código numérico que removemos por não ter valor preditivo. Não há, portanto, tratamento de dado pessoal sensível no sentido da LGPD.

Ainda assim, mantivemos duas decisões conservadoras: o CSV **não é versionado** no repositório — quem quiser reproduzir baixa direto da fonte, respeitando os termos do Kaggle — e todos os materiais do projeto (README, relatório, notebook e vídeo) reforçam que o modelo é uma ferramenta de **apoio à decisão**. O risco de *automation bias*, em que o profissional passa a confiar na saída do modelo sem checagem, é real e foi tratado explicitamente na discussão crítica do relatório.

A.9. Conclusão

O Breast Cancer Wisconsin (Diagnostic) foi escolhido porque é o ponto de encontro entre um tema de saúde da mulher com relevância real, um problema de classificação bem posto, dados limpos e interpretáveis, e um custo computacional compatível com o prazo e os equipamentos do grupo. Essa combinação permitiu que o esforço fosse para o que o desafio de fato avalia: um pipeline correto, sem vazamento de dados, com escolha de modelo justificada por validação cruzada e resultados explicados de forma crítica.

A.10. Referências deste anexo

- UCI Machine Learning Repository — Breast Cancer Wisconsin (Diagnostic) Data Set.
- Kaggle — Breast Cancer Wisconsin (Diagnostic): kaggle.com/datasets/uciml/breast-cancer-wisconsin-data
- Street, W. N.; Wolberg, W. H.; Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. SPIE, v. 1905.
- World Health Organization — Breast cancer fact sheet.
- Instituto Nacional de Câncer (INCA) — Estimativa de incidência de câncer no Brasil.
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.
- Lundberg, S.; Lee, S. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS.