

Classificação de Câncer de Mama com Machine Learning

Apoio ao diagnóstico (maligno × benigno) a partir de imagens de FNA

Parte	Integrante	Responsabilidade
A	Luis Conrado	Dataset, contexto e Análise Exploratória (EDA)
B	Beatriz Honey	Encoding, correlação, split e pipeline de pré-processamento
C	Pedro Henrique Klein	Modelagem (≥ 2 algoritmos de classificação)
D	Rodrigo Edson Fernandes	Avaliação, métricas e explicabilidade (SHAP)
E	Alexandre Akio	Integração, documentação, relatório e vídeo

Grupo 17 • Repositório: github.com/LuisEduardoOuroConrado/tech-challenge-fase1-g17
Vídeo de apresentação: <inserir link do YouTube/Vimeo>

Resumo

Este trabalho desenvolve um sistema de **Machine Learning** para apoiar a classificação de tumores de mama em **malignos (M)** ou **benignos (B)**, utilizando o dataset público *Breast Cancer Wisconsin (Diagnostic)*, com 569 amostras e 30 atributos numéricos extraídos de imagens de aspiração por agulha fina (FNA). O pipeline cobre análise exploratória, pré-processamento sem vazamento de dados (*data leakage*), comparação de seis algoritmos por validação cruzada e avaliação final em conjunto de teste independente. O modelo selecionado — **Regressão Logística** — alcançou **96,5% de acurácia** e **92,9% de recall** para a classe maligna no teste. Adota-se o **recall da classe maligna** como métrica principal, por ser o erro de *falso negativo* o de maior gravidade clínica. Reforça-se que a solução é uma ferramenta de **apoio** — a decisão final é sempre do profissional de saúde.

1. Introdução e contexto clínico

O câncer de mama está entre os tipos de câncer mais frequentes em mulheres, e o diagnóstico precoce é determinante para melhorar o prognóstico e reduzir a mortalidade. A análise de imagens de FNA (*Fine Needle Aspiration*) de uma massa mamária permite extrair características numéricas do núcleo celular — tamanho, textura, irregularidade da borda, concavidade, entre outras — que podem ser exploradas por algoritmos de aprendizado de máquina.

O objetivo do projeto é construir um classificador binário que distinga tumores malignos de benignos a partir dessas características. Em um contexto clínico, um **falso negativo** (classificar como benigno um tumor de fato maligno) costuma ser mais grave do que um **falso positivo**, pois adia um tratamento essencial. Por isso, a métrica priorizada é o **recall da classe maligna**.

***Importante:** o sistema apoia a decisão do profissional de saúde — nunca a substitui. O médico tem sempre a palavra final.*

2. Dataset

Característica	Detalhe
Base	Breast Cancer Wisconsin (Diagnostic)
Fonte	Kaggle / UCI Machine Learning Repository
Amostras	569 (357 benignos / 212 malignos)
Atributos	30 numéricos (10 medidas × mean / se / worst)
Alvo	diagnosis → M (maligno) / B (benigno) → 1 / 0
Qualidade	0 nulos e 0 duplicatas (após remover coluna vazia 'Unnamed: 32')

As 10 medidas de base são: *radius*, *texture*, *perimeter*, *area*, *smoothness*, *compactness*, *concavity*, *concave points*, *symmetry* e *fractal dimension*. Cada uma aparece em três agregações: média (*_mean*), erro padrão (*_se*) e pior valor (*_worst*).

3. Análise Exploratória — Parte A

A base é limpa: 569 amostras, sem valores nulos e sem duplicatas. As classes apresentam **desbalanceamento leve**, com predomínio de casos benignos (62,7% B contra 37,3% M), o que justifica o uso de **estratificação** na divisão treino/teste e a atenção a métricas além da acurácia.




Figura 1 — Distribuição das classes no dataset.

Comparando as distribuições das features `_mean` por diagnóstico, observa-se que tumores malignos tendem a apresentar valores maiores de tamanho e irregularidade (raio, área, concavidade e *concave points*), com clara separação entre as curvas.




Figura 2 — Distribuições de features selecionadas por diagnóstico.

A matriz de correlação evidencia forte associação entre medidas de tamanho — *radius*, *perimeter* e *area* — antecipando um problema de **multicolinearidade** a ser tratado no pré-processamento.




Figura 3 — Matriz de correlação das features *_mean.

4. Pré-processamento — Parte B

- **Remoção do id:** identificador sem valor preditivo, descartado.
- **Encoding do alvo:** diagnosis convertido de texto para número — B = 0, M = 1.
- **Análise de correlação:** foram identificados **21 pares** de features com correlação acima de 0,9 (ex.: radius_mean × perimeter_mean ≈ 0,998), confirmando multicolinearidade.
- **Split estratificado 80/20:** 455 amostras de treino e 114 de teste, preservando a proporção de classes (≈ 62,6% B / 37,4% M em ambos os conjuntos).
- **Pipeline com StandardScaler:** a padronização é ajustada **apenas no treino** e aplicada ao teste, evitando vazamento de dados (*data leakage*).

*O uso de **Pipeline** garante que todo o pré-processamento seja reproduzível e que a escala aprendida no treino nunca contamine a avaliação do teste.*

5. Modelagem — Parte C

Foram treinados e comparados **seis algoritmos** de classificação: Regressão Logística, SVM (kernel RBF), Random Forest, KNN, Naive Bayes e Árvore de Decisão. A seleção usou **validação cruzada estratificada (5-fold)** aplicada somente ao conjunto de treino, de modo a **não usar o teste** para escolher o modelo. Cada algoritmo foi encapsulado em um Pipeline com StandardScaler para manter a padronização correta dentro de cada *fold*.

Modelo	Accuracy	Precision (M)	Recall (M)	F1 (M)
Regressão Logística	0,974	0,977	0,953	0,964
SVM (RBF)	0,971	0,977	0,947	0,961
Random Forest	0,963	0,964	0,935	0,949
KNN	0,965	0,988	0,918	0,951
Naive Bayes	0,938	0,925	0,912	0,917
Árvore de Decisão	0,921	0,920	0,865	0,890

Tabela 1 — Média das métricas na validação cruzada (5-fold) sobre o treino. Linha destacada = modelo escolhido.




Figura 4 — Comparação visual dos modelos na validação cruzada.

A **Regressão Logística** apresentou o melhor equilíbrio, liderando em recall e F1 da classe maligna e mantendo alta acurácia. Além do desempenho, é um modelo **interpretável** (seus coeficientes têm leitura direta), o que é desejável em aplicações de saúde. Por isso foi selecionada como modelo final e treinada com todo o conjunto de treino (455 amostras).

6. Avaliação e explicabilidade — Parte D

Avaliação final no conjunto de teste independente (114 amostras nunca vistas):

Métrica (classe Maligna)	Valor
Accuracy	0,965
Precision	0,975
Recall (métrica principal)	0,929
F1-score	0,951




Figura 5 — Matriz de confusão no teste. $TN=71$, $FP=1$, $FN=3$, $TP=39$.

Por que o recall da classe maligna é a métrica principal?

O erro mais crítico é o **falso negativo**: um paciente com tumor maligno classificado como benigno deixa de receber tratamento no tempo adequado, com consequências potencialmente fatais. Um **falso positivo**, por outro lado, leva a exames adicionais (como biópsia) e gera ansiedade, mas não coloca a vida em risco da mesma forma. Maximizar o recall da classe maligna significa minimizar os falsos negativos.

No teste, o modelo produziu apenas **1 falso positivo** e **3 falsos negativos**, identificando corretamente 39 dos 42 casos malignos — recall de 92,9%.

Explicabilidade (coeficientes e SHAP)

A interpretabilidade foi analisada por dois caminhos complementares: os **coeficientes** da Regressão Logística e os valores **SHAP**. Features como *concave points*, *radius*, *perimeter* e *area* aparecem entre as mais influentes para a predição de malignidade, coerentes com a intuição clínica (tumores malignos tendem a ser maiores e mais irregulares). Vale notar que a correlação isolada de uma variável com o alvo não determina, sozinha, sua importância no modelo: os coeficientes refletem a contribuição de cada feature **considerando as demais**, o que é relevante diante da multicolinearidade observada na

EDA.

7. Discussão crítica e limitações

Os resultados são promissores ($\approx 96\%$ de acurácia e $92,9\%$ de recall maligno), mas **não** tornam o modelo apto ao uso clínico direto. As principais limitações são: (i) o tamanho reduzido e a origem específica do dataset, que limitam a generalização para outras populações e equipamentos; (ii) a ausência de validação externa em dados independentes; e (iii) a necessidade de calibração de *threshold* caso se deseje reduzir ainda mais os falsos negativos.

*Na prática, o modelo deve ser tratado como **ferramenta de apoio à decisão**, útil para triagem e priorização de casos que merecem maior atenção. A decisão final permanece com o profissional de saúde, que considera histórico clínico e demais exames.*

8. Reprodutibilidade e entregáveis — Parte E

Estrutura do repositório:

```
tech-challenge-fase1-g17/
■ data/raw/ # CSV do Kaggle (não versionado)
■ notebooks/01_pipeline_eda_preprocessamento.ipynb
■ reports/figuras/ # figuras geradas pela EDA
■ src/run_eda.py # gera as figuras da EDA sem Jupyter
■ requirements.txt
■ README.md
```

Como reproduzir:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1 # Windows (Linux/Mac: source .venv/bin/activate)
pip install -r requirements.txt
# baixar o CSV do Kaggle e salvar em data/raw/data.csv
python src/run_eda.py # gera as figuras da EDA
```

Dataset: baixar em [kaggle.com/datasets/uciml/breast-cancer-wisconsin-data](https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data) e salvar como `data/raw/data.csv`. É necessário estar logado no Kaggle para o download.

Entregáveis finais: (1) repositório Git com código e README; (2) este relatório técnico em PDF, com link do repositório; (3) vídeo de apresentação de até 15 minutos (YouTube/Vimeo).

9. Conclusão

O projeto entregou um pipeline completo e reproduzível de classificação de câncer de mama, da análise exploratória à avaliação com explicabilidade. A Regressão Logística mostrou-se o melhor compromisso entre desempenho ($96,5\%$ de acurácia, $92,9\%$ de recall maligno) e interpretabilidade. Priorizando o recall da classe maligna, o sistema reduz o risco do erro mais grave — o falso negativo — e se posiciona como uma ferramenta de **apoio** ao diagnóstico, sempre subordinada à avaliação de um profissional de saúde.

Referências

- UCI Machine Learning Repository — Breast Cancer Wisconsin (Diagnostic) Data Set.

- Kaggle — Breast Cancer Wisconsin (Diagnostic): kaggle.com/datasets/uciml/breast-cancer-wisconsin-data
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.
- Lundberg & Lee (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS.